2 项目概要及价值- 研究意义

聚焦于大模型的深度思考激活机制，并创新性地引入对抗博弈框架，来驱动模型精准识别并动态扩展其知识边界

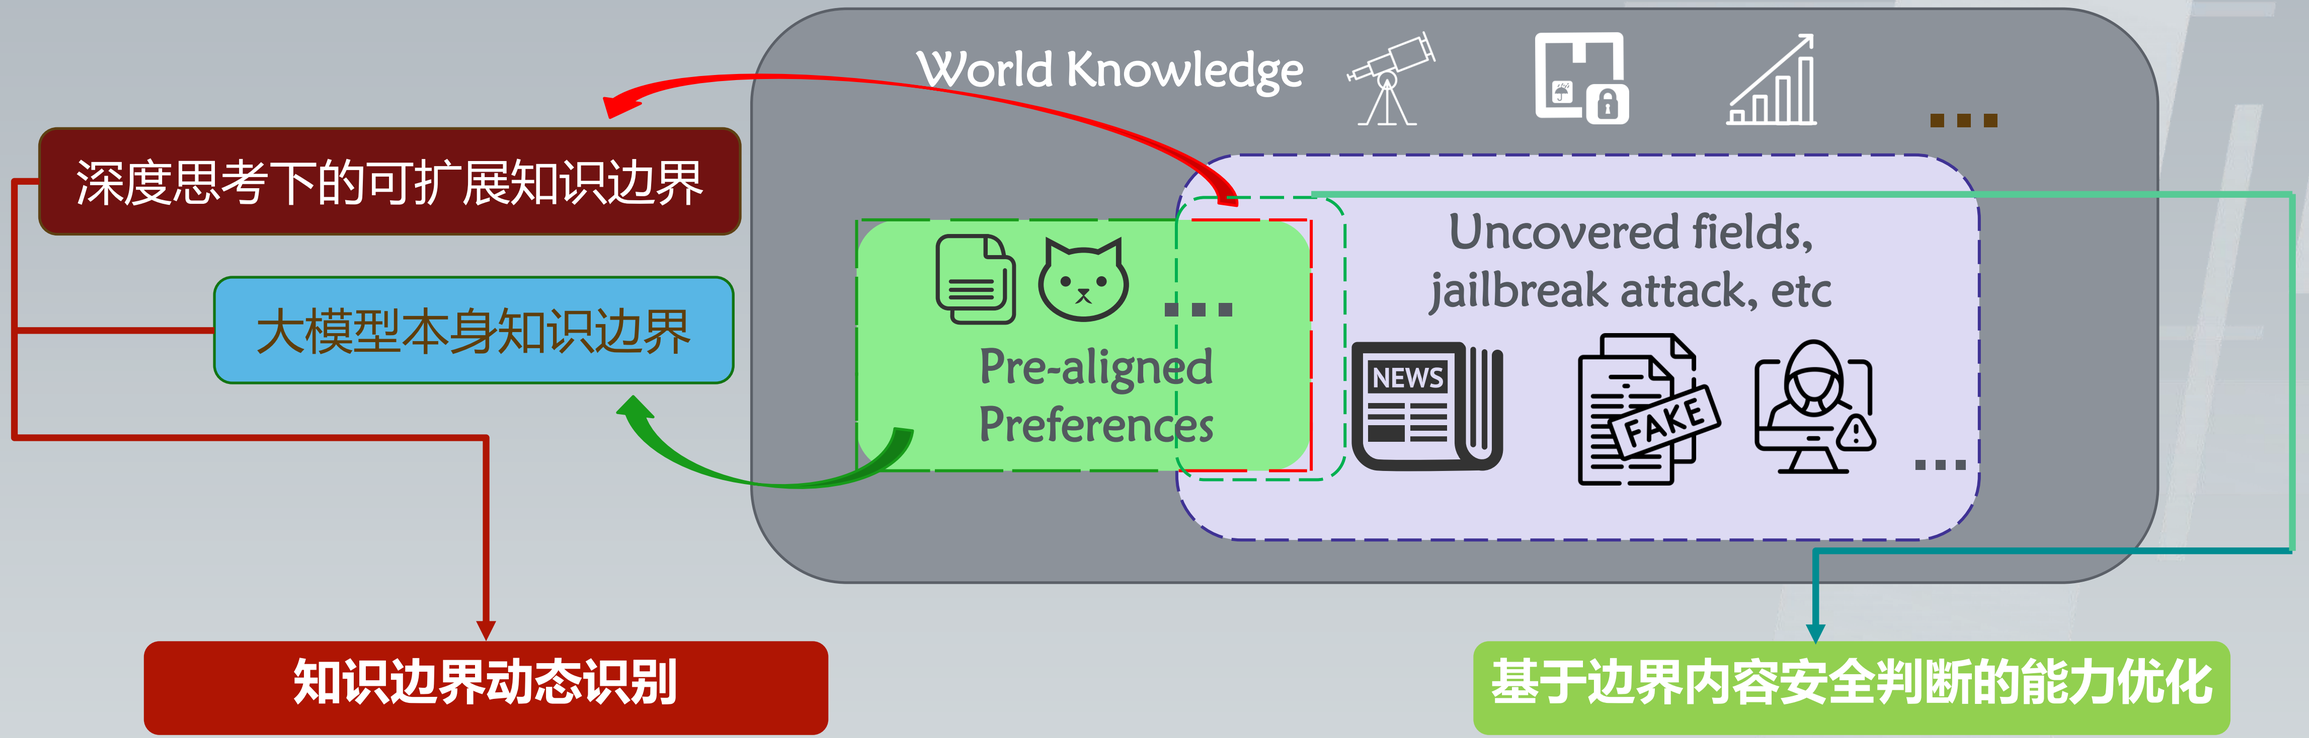

1. **提升审核准确性与效率：**通过让模型学会动态决策，实现审核效果与效率的较好平衡；
2. **增强模型鲁棒性与适应性：**设计的对抗博弈能够不断迫使审核模型学习和适应新型未知的安全攻击；
3. **提高决策的可解释性：**优化的深度思考过程，能为每次复杂的审核决策提供清晰、简洁的推理依据。

3 项目执行方案- 对抗性博弈框架

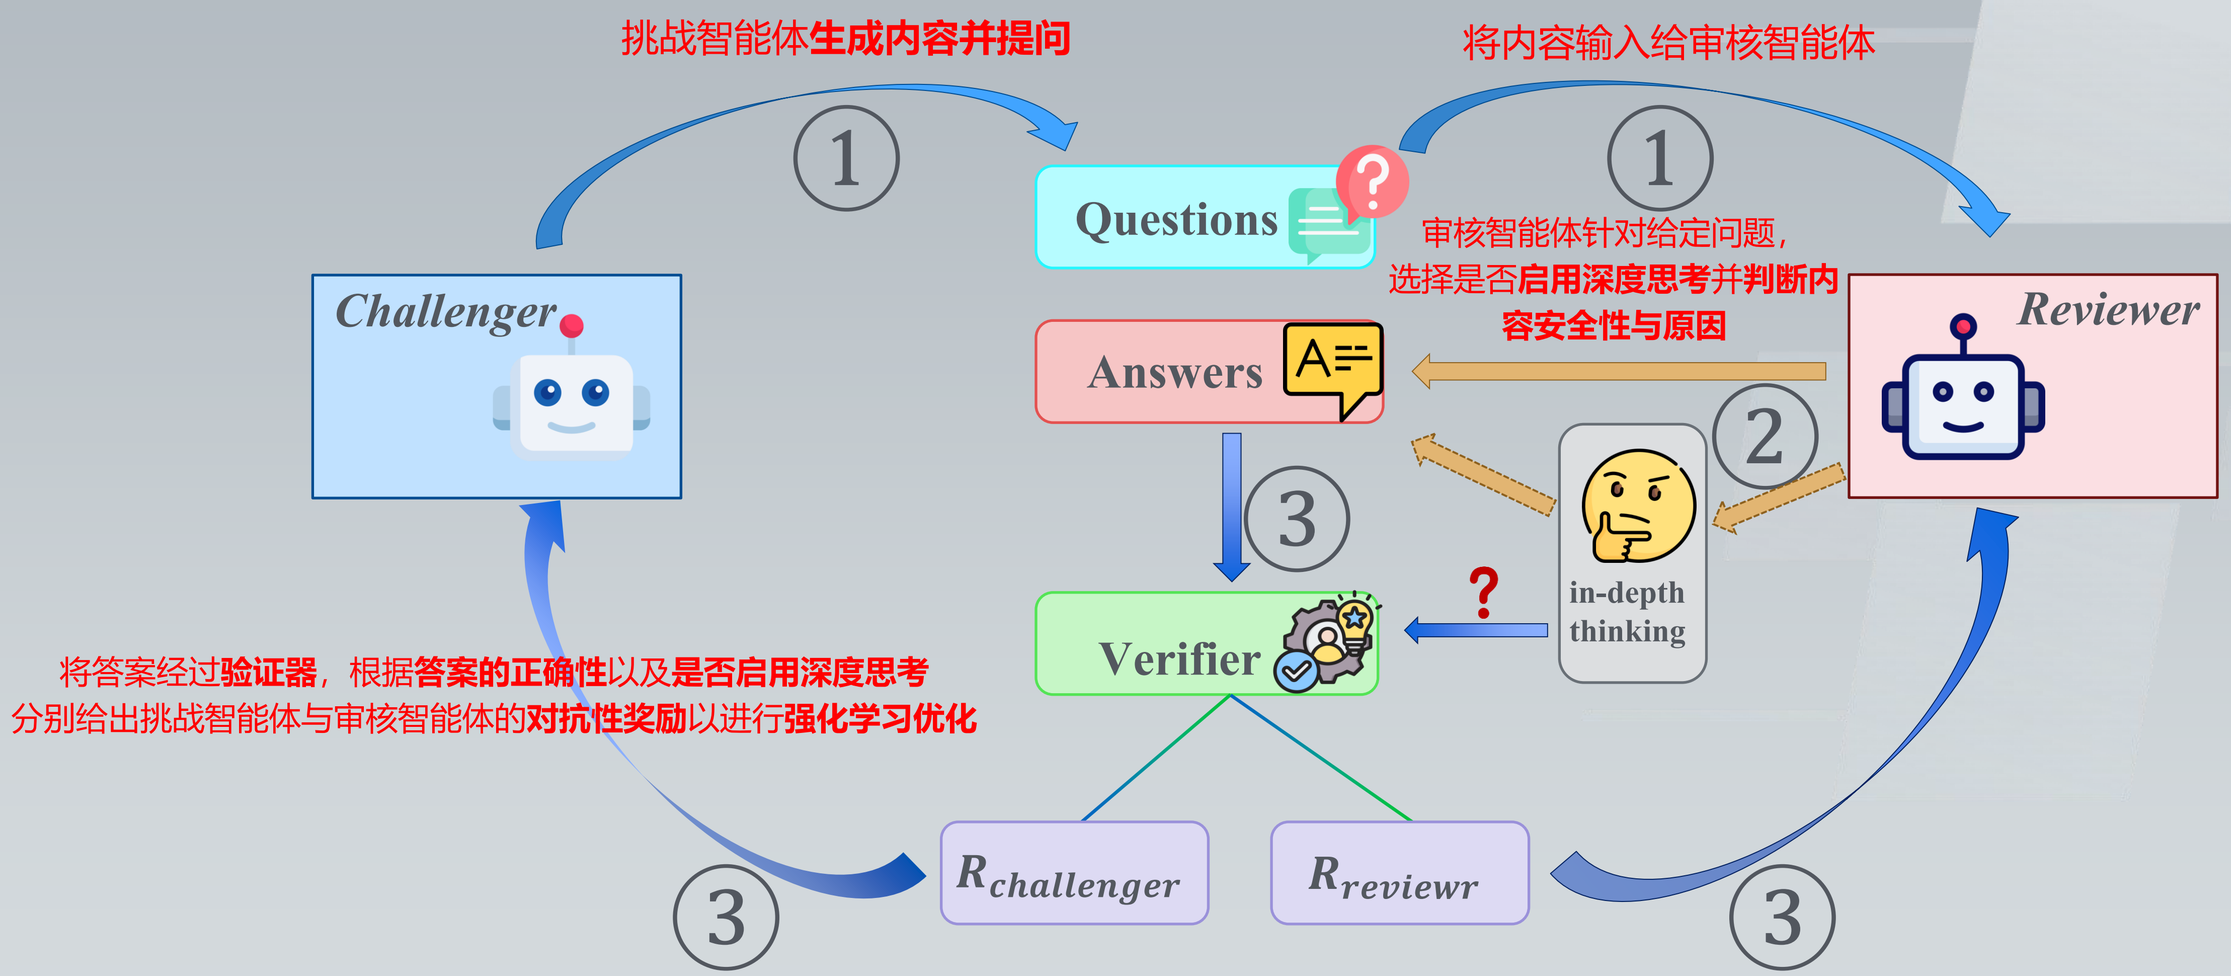

✓该过程可形式化为一个Stackelberg博弈或迭代对抗训练框架

3 项目执行方案- 自动化QA对生成机制

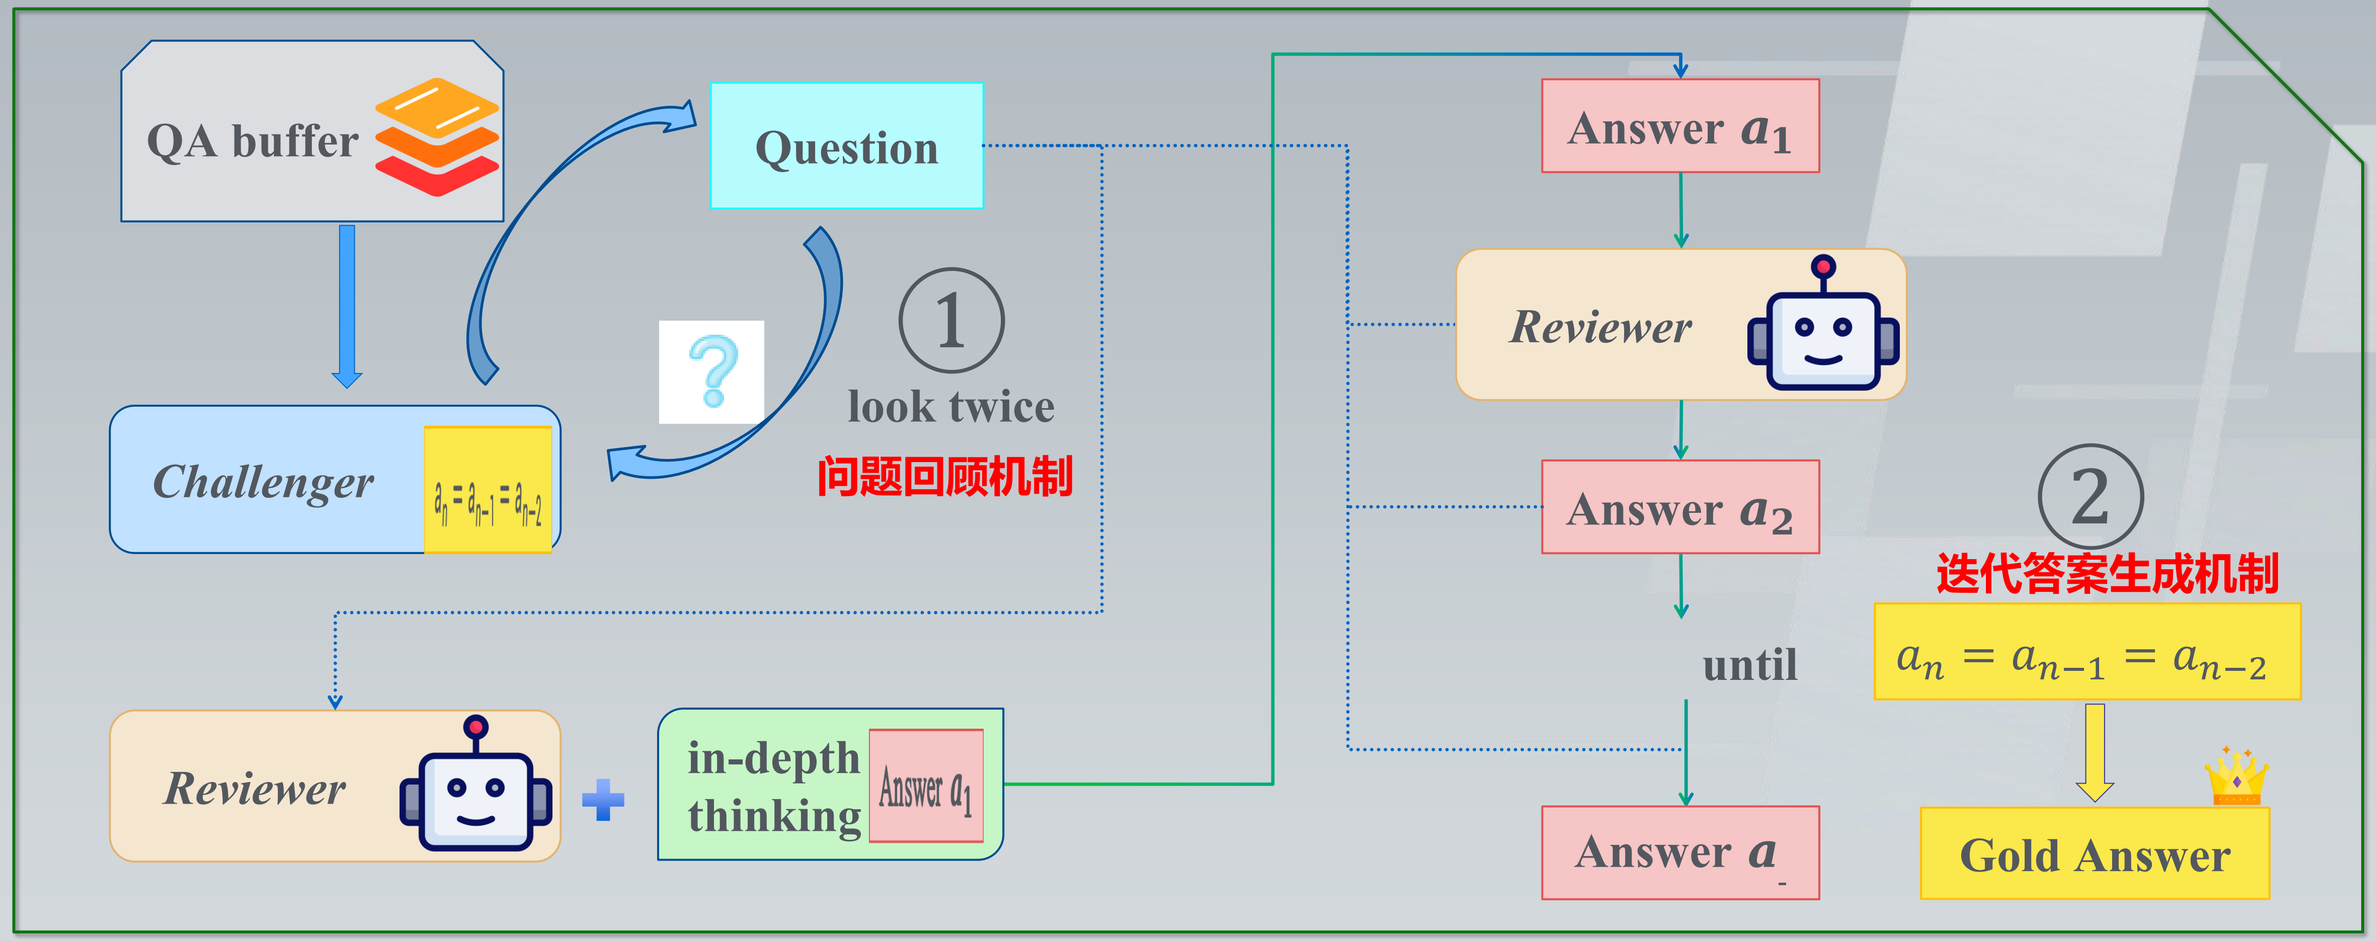

基于参考文本与对应安全性推断答案构建的回放池，挑战智能体提出**新的隐含安全问题的文本**；
审核智能体启用深度思考，进行**多次审核与反思**，输出**置信度较高的答案**作为后续训练的ground truth。

3 项目执行方案 - 对抗性奖励设计

通过对正确答案长度与该问题的最短正确答案长度进行比较，构建辅助奖励以激发模型自主压缩深度思考的能力，提高模型简洁性和可读性

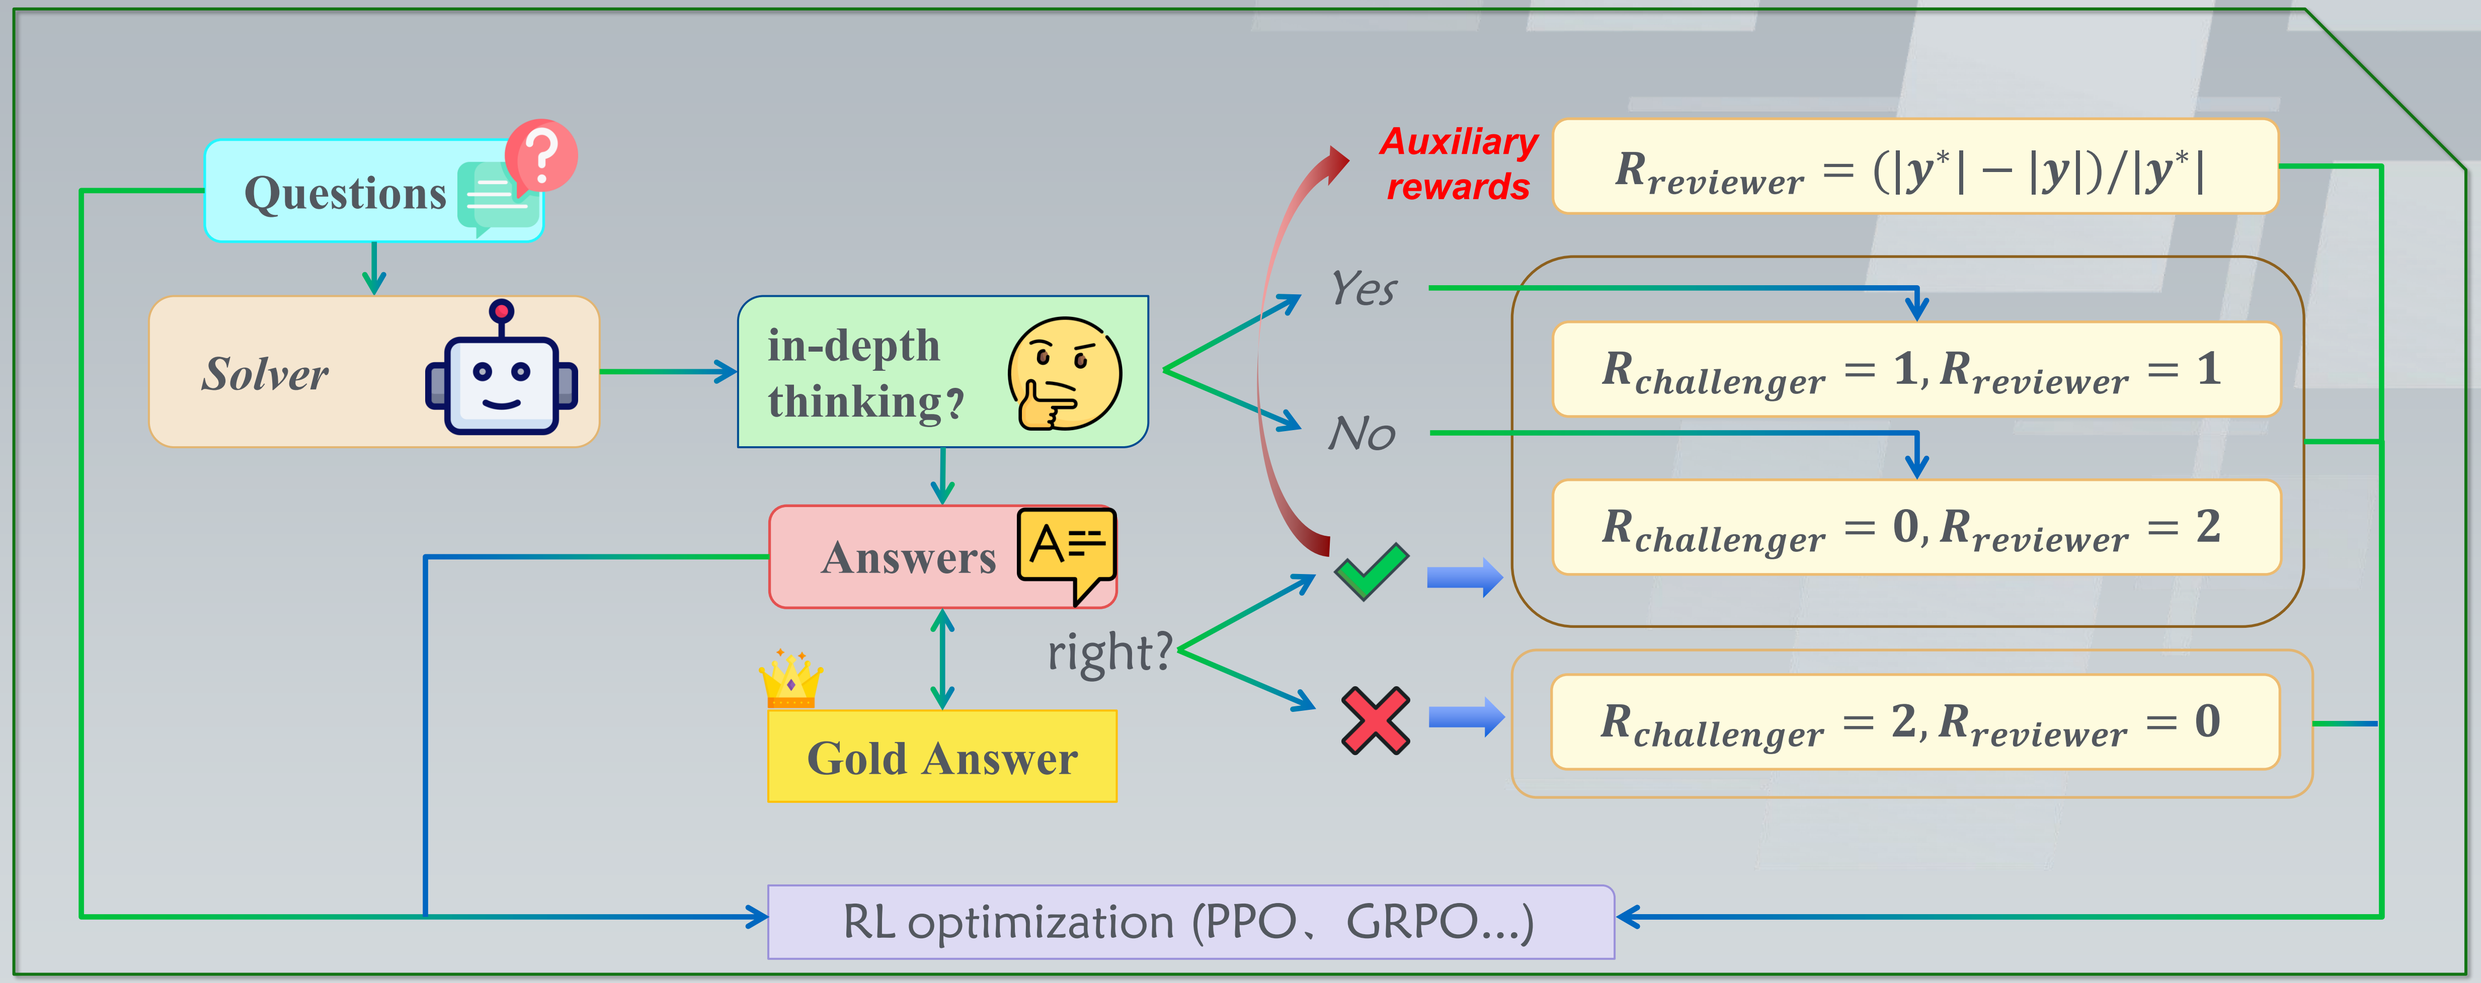

通过基于判断**答案的正确性**与**是否启动深度思考**设计**对抗性奖励**，从而实现挑战智能体与审核智能体的对抗博弈，鼓励挑战智能体尽可能生成难以判断的文本内容，并且鼓励审核智能体尽可能通过浅层思考做出正确判断。

3 项目执行方案- 动态策略熵正则化

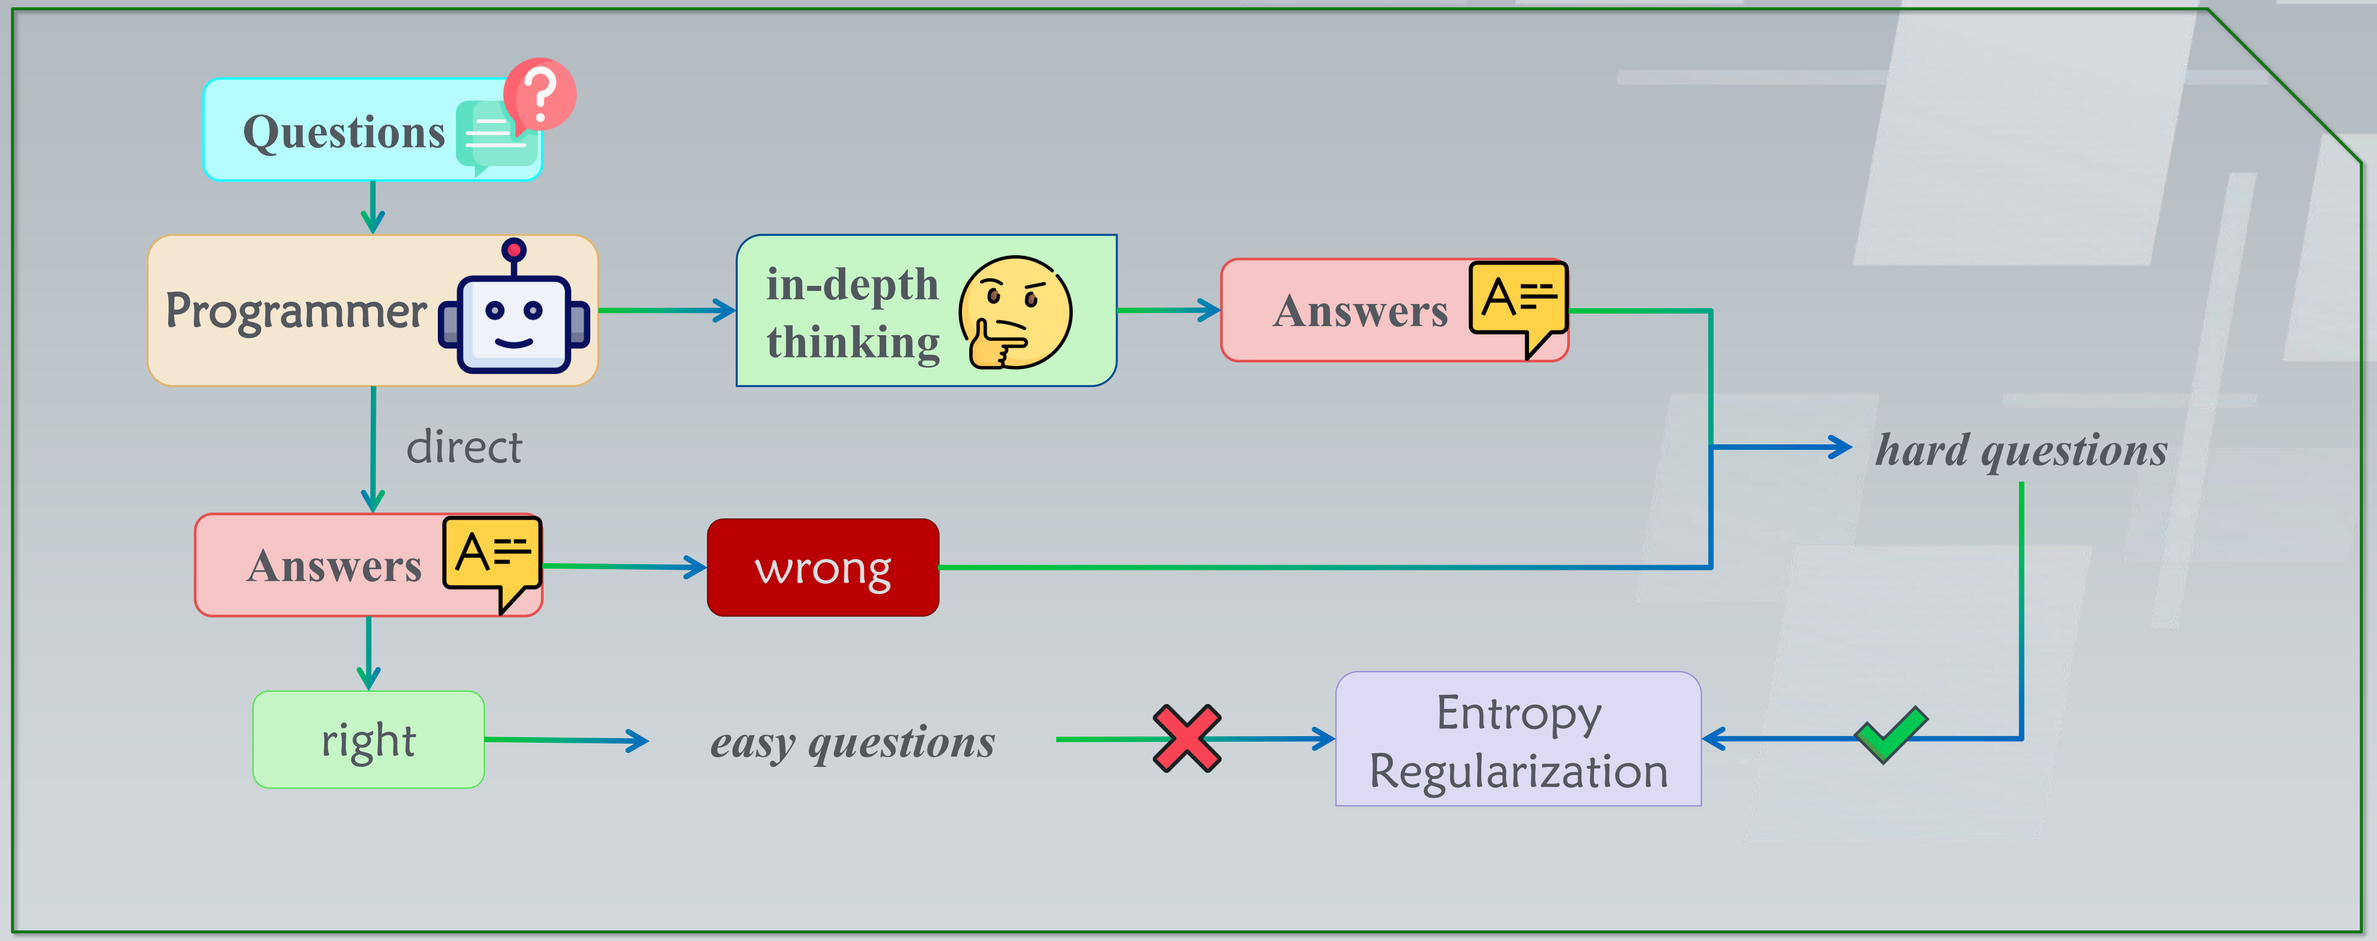

通过训练过程中的问题进行难度分类，对困难问题优化采用熵正则化以加强模型探索能力，同时避免迭代答案生成时审核智能体的过度自信；对简单问题优化不采用熵正则化，提高模型对知识边界内问题的置信度。